Practice Problem , RNN (Module 3)

Q1. Machine Learning-এ dataset বলতে কী বোঝায়? কোনো machine learning বা deep learning model train করার আগে dataset কেন লাগে, নিজের ভাষায় বুঝিয়ে লেখো।

Q2. NLP-তে tokenization বলতে কী বোঝায়? একটা পুরো sentence-কে neural network-এ দেওয়ার আগে ছোট ছোট token-এ ভাঙা হয় কেন?

Q3. Preprocessing function-এ text-কে lowercase করা হয়েছে। "What" আর "what"-কে যদি দুটো আলাদা word ধরা হয়, তাহলে কী সমস্যা হতে পারে?

Q4. NLP-তে vocabulary কী? "what", "is", "capital"-এর মতো word কীভাবে numerical index-এ map হয়, একটা ছোট উদাহরণ দিয়ে বোঝাও।

Q5. <UNK> (Unknown) token কেন ব্যবহার করা হয়? Model যদি এমন কোনো word পায় যেটা vocabulary-তে নেই, তখন কী ঘটে?

Q6. Neural network numerical tensor নিয়ে কাজ করে। "What is the capital of France" এই sentence-টা সরাসরি PyTorch model-এ দেওয়া যায় না কেন?

Q7. Dataset আর DataLoader-এর মধ্যে পার্থক্য কী? batch_size এবং shuffle দিয়ে কী করা হয়, আর training-এ এগুলো কেন দরকার?

📖 আরও ভালোভাবে বুঝতে চাইলে এটা দেখতে পারো: PyTorch: Datasets & DataLoaders tutorial

Q8. nn.Embedding() ঠিক কী কাজ করে? প্রতিটা word-কে শুধু একটা random integer দিয়ে represent করার চেয়ে embedding ব্যবহার করা বেশি কার্যকর কেন?

📖 আরও ভালোভাবে বুঝতে চাইলে এটা দেখতে পারো: PyTorch docs: nn.Embedding

Q9. PyTorch-এ squeeze() আর unsqueeze()-এর পার্থক্য কী? একটা single sequence RNN-এ দেওয়ার সময় unsqueeze(0) কেন কাজে লাগে? Tensor shape-এর আগে-পরের একটা উদাহরণ দাও।

📖 আরও ভালোভাবে বুঝতে চাইলে এটা দেখতে পারো: PyTorch docs: torch.squeeze

📖 আরও ভালোভাবে বুঝতে চাইলে এটা দেখতে পারো: PyTorch docs: torch.unsqueeze

Q10. RNN একটা word sequence কীভাবে process করে, conceptually বোঝাও। Hidden state কী, আর আগের word-এর information পরের word-এর processing-কে কীভাবে প্রভাবিত করে?

📖 আরও ভালোভাবে বুঝতে চাইলে এটা দেখতে পারো: PyTorch docs: nn.RNN

Q11. nn.CrossEntropyLoss() আসলে কী measure করে? Vocabulary-র অনেক possible word-এর মধ্য থেকে একটা word predict করার জন্য এটা উপযুক্ত কেন?

📖 আরও ভালোভাবে বুঝতে চাইলে এটা দেখতে পারো: PyTorch docs: nn.CrossEntropyLoss

Q12. Code-এ Adam optimizer ব্যবহার করা হয়েছে। loss.backward()-এর পর optimizer কী করে? Model-এর parameter বারবার update করতে হয় কেন, একবার করলে কেন হয় না?

📖 আরও ভালোভাবে বুঝতে চাইলে এটা দেখতে পারো: PyTorch docs: optim.Adam

Q13. Training loop-এ answer-এর শুধু প্রথম token-কে target ধরা হয়েছে: target = answer[0][0].unsqueeze(0) এই approach দিয়ে একটা পুরো question-answering task ঠিকমতো শেখা যায় না কেন? যদি model-কে পুরো answer generate করতে হতো, তাহলে training objective কীভাবে বদলাতে হতো?

Q14. Model পুরো question নিয়ে RNN দিয়ে pass করে এবং vocabulary থেকে মাত্র একটা token predict করে। পুরো answer generate করার জন্য এই architecture কি যথেষ্ট? একটা proper sequence-to-sequence QA model বানাতে architecture ও training-এ কী কী পরিবর্তন লাগবে?

> 📖 আরও ভালোভাবে বুঝতে চাইলে এটা দেখতে পারো: PyTorch docs: nn.RNN (RNN, GRU, LSTM-এর কাছাকাছি ধারণার জন্য)

Q15. Module er notebook-এ training-এর আগে complete dataset ব্যবহার করে vocabulary বানানো হয়েছে। পরে আলাদা test set ব্যবহার করলে এটা data leakage বা evaluation-design-এর সমস্যা হতে পারে কেন? Train/validation/test split থাকলে vocabulary সঠিকভাবে কীভাবে বানাবে?

(Some concepts may seem hard now, but hopefully this QnA will help you increase self-exploration and deeper understanding of this topic)